SCIENCES SORBONNE UNIVERSITÉ

Examen de machine learning
Année universitaire 2020-2021

Nom:			
Prénom:			
Parcours	ISI gr1	ISI gr2	SAR

Examen de TP sur 25 pts

Exercice 1 (7pts)

On exécute le programme :

```
[X, y, name]=np.load("TP1.npy")
print(X.shape)
print(y.shape)
```

qui nous donne les sorties

```
Out[]: (1000, 100)
Out[]: (1000,)
```

1. (1pt) Quelle est le nombre d'exemples N et la dimension du problème n?

N=1000
n=100

On réalise ensuite une division des données avec :

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25)

2. (1pt) Quelle sera la taille des variables X_train, X_test, y_train et y_test ?

X_train 750x100
X_test 250x100
y_train 750x1
y_test 250x1

On réalise ensuite une standardisation des données avec :

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25)
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.fit_transform(X_test)
```

3. (2pts) Ce code est-il correct ? Si non, apporter les modifications nécessaires. Quelle sera la taille de X_train et X_test ?

Non, il n'est pas correct
scaler = StandardScaler()
scaler.fit(X_train)
X_train = scaler.transform(X_train)
X_test = scaler.transform(X_test)
La taille des variables ne change pas

On souhaite maintenant réduire la dimension des données avec :
pca=PCA(n_components=40)
pca.fit(X_train)
X_train=pca.transform(X_train)
X_test=pca.transform(X_test)

4. (1pt) Le code est-il correct ? Si non, apporter les modifications nécessaires. Quelle sera la taille de X_train et X_test ? Faut-il aussi appliquer pca.transform sur y_train et y_test ?

Oui, le programme est correct
X_train 750x40
X_test 250x40

Non, pas de PCA sur les labels !

On lance enfin la classification et affiche la matrice de confusion :

$$\begin{bmatrix} 5 & 1 & 0 \\ 7 & 15 & 5 \\ 2 & 5 & 10 \end{bmatrix}$$

5. (2pts) Combien y a-t-il de classes ? Combien y a-t-il d'exemples par classe ? Quel est le taux de reconnaissance ?

Il y a 3 classes
C1 – 6 exemples
C2 – 27 exemples
C3 – 17 exemples
Taux de reco = 30/50 *100 = 60%

Exercice 2 (5pts)

On souhaite réaliser une classification binaire en modélisant une seule classe. Pour cela, on a calculé les probabilités p_test[i] que chaque exemple de test i appartienne à la classe 1. Ainsi, si p_test[i]>seuil, l'exemple sera attribué à la classe C1. Sinon, il sera classifié C0. La vérité de terrain est stockée dans y_test[i]. Pour un seuil donné, on souhaite estimer le nombre de vrais positifs (TP), faux posititifs (FP), vrais négatifs (TN) et faux négatifs (FN).

1. (3pts) Compléter le programme suivant :

```
TP , FP , TN , FN = 0, 0, 0, 0
for i in range(len(y_test)):
        if p_test[i] > seuil:
                y_pred[i] = 1
        else:
                y_pred[i] = 0
        if cl==1 and y_test[i]==1:
                TP = TP+1
        if cl==1 and y_test[i]==0:
                FP = FP +1
        if cl==0 and y_test[i]==0:
                TN = TN+1
        if cl==0 and y_test[i]==1:
                FN = FN+1
```

Le programme donne :
TP= 100 TN= 150 FP= 50 FN= 10

2. (2pt) Combien y a-t-il d'exemple dans chaque classe ? Que valent la sensibilité et la spécificité ?

110 exemples positifs et 200 exemples négatifs
Sensiblité = TP/(TP+FN) = 100/110
Spécificité = TN/(TN+FP) = 150/200

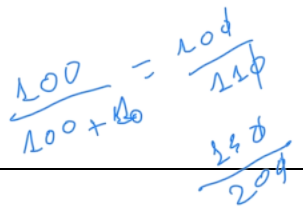

Exercice 3 (3 pts)

On souhaite réaliser une classification en utilisant un arbre de décision :
tree1 = DecisionTreeClassifier(criterion ='entropy', max_depth = M)
La partition de l'expace ontenur, sur ces données 2D, est représentée ci-contre.

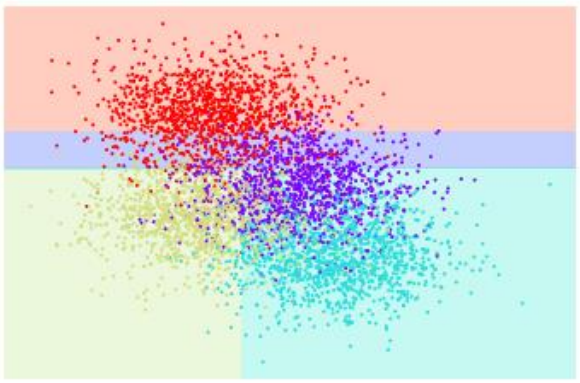

1. (1.5pts) Quelle valeur de M a été utilisée ? Justifier votre raisonnement

M = 2 : lors de la première découpe, on obtient 2 cases. Chacune est divisée lors de la seconde découpe pour arriver à 4 partitions.

On souhaite réaliser une classification avec des SVM. En utilisant toujours les mêmes données d'apprentissage, on obtient les frontières de décision avec 4 paramétrages :

(a) noyau lineaire et C=1
(b) noyau lineaire et C=1000
(c) noyau rbf et C=1
(d) noyau rbf et C=1000

2. (1.5pts) Réattribuer le paramétrage utilisé pour chaque courbe :

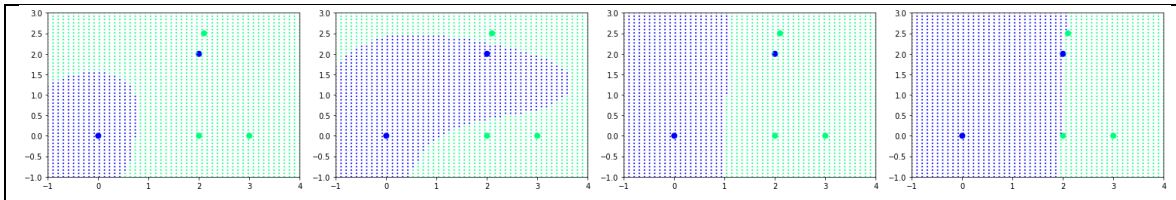

c d a b

Exercice 4 (10 pts)

On souhaite lancer un apprentissage avec un réseau de neurone. Pour cela, on télécharge les données : (X_train, y_train), (X_test, y_test) = load_data(). La base de test est composée de 3 exemples tels que y_test=[0 2 2]. Afin de mettre en forme les étiquettes, on réalise :
Y_ test = tf.keras.utils.to_categorical(y_ test, 4)

1. (2pts) Donner les valeurs de la variable Y_ test

$$Y\_test = \begin{bmatrix} 1000 \\ 0010 \\ 0010 \end{bmatrix}$$

On définit un réseau de neurones avec :

```
inputs = Input(shape=(10,10,1))
x= inputs
x=Flatten()(x)
x=Dense(20, activation='relu')(x)
x=Dropout(0.5)(x)
outputs=Dense(10, activation='softmax')(x)
model = Model(inputs, outputs)
```

2. (2pts) Combien y a-t-il de paramètres à estimer ?

(100*20+20) + (20*10+10) = 2,230

On ajoute entre les deux premières lignes précédentes la ligne :
x=Convolution2D(10,(3,3), activation='relu',padding='same')(x)

3. (2pts) Quelle sera la taille du tenseur en sortie de cette couche ? Combien de paramètres y a-t-il à estimer avec cette nouvelle architecture (reprendre tous le réseau) ?

Le tenseur aura pour dimension 10x10x10

(10*3*3+10) +(1000*20+20) + (20*10+10) = 20,330

On réalise l'apprentissage d'un réseau MLP avec 4 taux d'apprentissage différents (1 ; 0.1 ; 0.01 ; 0.001) et on obtient les 4 courbes d'apprentissage suivantes.

4. (2pts) Réattribuer le taux utilisé dans chaque cas. Quelle courbe vous parait la plus adaptée ?

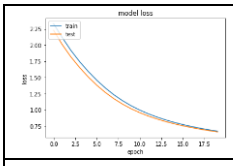	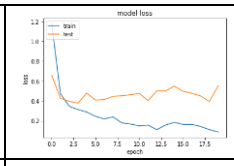	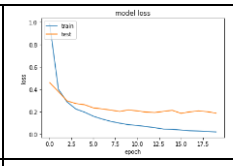	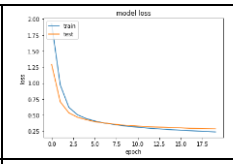
0.001	1	0.1	0.01
La dernière avec un taux de 0.01. Bonne généralisation et apprentissage assez rapide			

On a réalisé l'apprentissage d'un réseau MLP (1 couche cachée) en introduisant une couche de dropout de taux rate (0 ; 0.5 ; 0.7) entre les deux dernières couches. x=Dropout(rate)(x). Pour mémoire, la documentation donne :
rate: Float between 0 and 1. Fraction of the input units to drop

5. (2pts) Réattribuer le taux utilisé dans chaque cas. Quelle courbe vous parait la plus adaptée ?

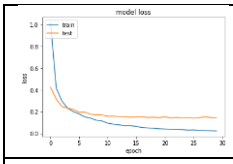	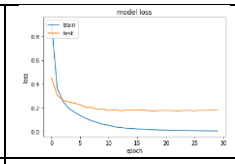	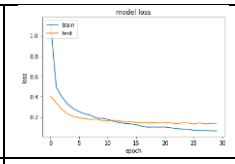
0.5	0	0.7
La dernière qui présente la meilleure généralisation		